

# Analysis Report

## 1. 공격 성공률 결과

본 실험에서는 MNIST와 CIFAR-10 데이터셋에 대해 FGSM과 PGD 공격을 적용하고, 다양한 epsilon 값에 따른 공격 성공률을 측정하였다.

Attack Success Rate Table

| 데이터셋     | 공격법             | $\epsilon=0.05$ | $\epsilon=0.10$ | $\epsilon=0.20$ | $\epsilon=0.30$ |
|----------|-----------------|-----------------|-----------------|-----------------|-----------------|
| MNIST    | Targeted FGSM   | 0.5%            | 1.8%            | 13.1%           | 47.4%           |
| MNIST    | Untargeted FGSM | 2.8%            | 11.1%           | 55.2%           | 95.6%           |
| MNIST    | Targeted PGD    | 0.5%            | 2.4%            | 55.8%           | 99.8%           |
| MNIST    | Untargeted PGD  | 4.1%            | 19.0%           | 95.5%           | 100.0%          |
| CIFAR-10 | Targeted FGSM   | 13.5%           | 8.9%            | 9.8%            | 8.2%            |
| CIFAR-10 | Untargeted FGSM | 90.2%           | 89.3%           | 90.9%           | 89.9%           |
| CIFAR-10 | Targeted PGD    | 99.6%           | 100.0%          | 100.0%          | 100.0%          |
| CIFAR-10 | Untargeted PGD  | 100.0%          | 100.0%          | 100.0%          | 100.0%          |

## 2. 공격 방법별 성능 분석

### (1) PGD가 FGSM보다 더 효과적인 이유

실험 결과에서 PGD 공격은 FGSM보다 훨씬 높은 공격 성공률을 보였다.

- FGSM은 단 한 번의 **gradient step**으로 perturbation을 생성하는 반면,
- PGD는 여러 번 **반복적으로 gradient를 적용**하며 탐색(iterative optimization)을 수행한다.

즉, PGD는 입력 이미지 주변의 더 넓은 탐색 공간에서 최적의 공격 방향을 찾기 때문에, 모델의 decision boundary를 보다 정밀하게 공략할 수 있다.

특히 CIFAR-10에서 PGD는 거의 모든 epsilon 값에서 100%에 가까운 성공률을 보이며, 이는 보다 복잡한 데이터에서 iterative 공격이 효과적임을 보여준다.

### (2) Targeted vs Untargeted 공격 비교

Untargeted 공격이 Targeted 공격보다 전반적으로 높은 성공률을 보였다.

- Untargeted 공격:
  - 목표: “아무 클래스나 틀리게 만들기”
  - 상대적으로 쉬운 문제
- Targeted 공격:
  - 목표: “특정 클래스(target)로 오분류 유도”
  - 훨씬 더 정밀한 조작 필요

MNIST에서도 동일한 경향이 나타났으며, 특히 작은 epsilon 영역에서는 Targeted 공격의 성공률이 매우 낮게 나타났다.

이는 모델의 예측을 특정 방향으로 이동시키는 것이 단순히 틀리게 만드는 것보다 훨씬 어려운 문제임을 의미한다.

### (3) CIFAR-10에서 FGSM Targeted 성능이 낮은 이유

CIFAR-10에서는 Targeted FGSM의 성능이 매우 낮고, epsilon 증가에도 큰 개선이 없었다.

- CIFAR-10은 MNIST보다 데이터 복잡도와 feature 다양성이 높음
- 단일 step 공격(FGSM)은 정확한 방향으로 feature를 조작하기 어려움
- 결과적으로 target class로 유도하는 데 실패

반면 PGD는 iterative 방식으로 이를 보완하여 높은 성능을 보인다.

## 3. epsilon 값의 영향 분석

### (1) epsilon 증가 → 공격 성공률 증가

MNIST 결과에서 확인되듯이, epsilon이 증가할수록 공격 성공률은 급격히 증가한다.

예:

- Untargeted FGSM: 2.8% → 95.6%
- Targeted PGD: 0.5% → 99.8%

이는 perturbation의 크기가 커질수록 입력 이미지가 원본에서 멀어지고, 모델이 더 쉽게 혼란을 겪기 때문이다.




### (2) Trade-off: 성공률 vs 시각적 자연스러움

그러나 epsilon이 커질수록 다음과 같은 문제가 발생한다:

| 요소        | 영향          |
|-----------|-------------|
| 공격 성공률    | 증가          |
| 시각적 품질    | 감소 (노이즈 증가) |
| 인간 인지 가능성 | 증가          |

즉, 작은 epsilon인 경우:

거의 보이지 않는 perturbation과 낮은 공격 성공률



큰 epsilon인 경우:

눈에 띄는 왜곡으로 사람도 판별 어려워 지나, 높은 공격 성공률

이러한 관계는 adversarial attack에서 trade-off로 작용한다.


Original  
Pred: truck (True: truck)



Adversarial ( $\epsilon=0.3$ )  
Pred: airplane



Perturbation  
(Magnified  $\times 15$ )



#### 4. 결론

본 실험을 통해 다음과 같은 결론을 도출할 수 있다:

1. PGD는 FGSM보다 강력한 공격 방법이다.
2. Untargeted 공격이 Targeted 공격보다 성공률이 높다.
3. epsilon이 증가할수록 공격 성공률은 증가하지만, 이미지 품질은 저하된다.
4. 비교적 복잡한 데이터셋(CIFAR-10)일수록 iterative 공격(PGD)이 효과적이다.